creative commons

COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.

변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

[UCI]I804:11034-000002232959

공학석사 학위논문

자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증

User Authentication Based on Keystroke Dynamics of Free Character Strings

2016년 2월

서울과학기술대학교 일반대학원
데이터사이언스학과

서 동 민

Master Thesis

User Authentication Based on Keystroke Dynamics of Free Character Strings

by

Dong Min Seo

Department of Data Science

The Graduate School

Seoul National University of Science and Technology

February 2016

자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증

User Authentication Based on Keystroke Dynamics of Free Character Strings

지도교수 이원영

이 논문을 공학석사 학위논문으로 제출함

2016년 2월

서울과학기술대학교 일반대학원

데이터사이언스학과

서 동 민

서동민의 공학석사 학위논문을 인준함

2016년 2월

심사위원장 조남욱 (인)

심사위원 이원영 (인)

심사위원 이윤호 (인)

User Authentication Based on Keystroke Dynamics of Free Character Strings

by

Dong Min Seo

A Master Thesis submitted to the Department of Data Science at the Graduate School Seoul National University of Science and Technology in partial fulfillment of the requirements for the degree of Master of Science

February 2016

Approved by

Won Young Lee

Advisor

목 차

요약 ····· i
표목차 ····· ii
그림목차 ····· iii

I. 서 론 ····· 1

II. 문헌 연구 ····· 4

III. 연구 방법 ····· 7
1. 키 시퀀스 정보를 활용하지 않은 방법 ····· 8
2. 키 시퀀스 정보를 활용한 통계적 기반의 방법 ····· 10
3. 키 시퀀스 정보를 활용한 기계학습 기반의 방법 ····· 13
4. 변수 조합 방법 ····· 16

IV. 실험 설계 ····· 18
1. 데이터 수집 ····· 18
2. 인증 방법 ····· 21
3. 성능 평가 지표 ····· 23

V. 실험 결과 ····· 25
1. 알고리즘에 따른 인증 성능 ····· 25
2. 사용 데이터 크기에 따른 인증 성능 ····· 28
3. 사용 데이터 언어에 따른 인증 성능 ····· 30
4. 변수 조합 방법 및 사용 변수에 따른 인증 성능 ····· 31

VI. 결 론 ····· 35

참고문헌 ····· 37
영문초록(Abstract) ····· 39

요 약

제 목 : 자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증

컴퓨터 네트워크 시스템에서 사용자 인증은 중요한 문제이다. 현재 대부분의 사용자 인증은 패스워드 기반 인증을 통해 이루어지고 있다. 패스워드 기반 인증에서는 패스워드가 유출될 경우 사용자를 가장한 침입자의 거짓 인증이 가능한 취약점이 있다. 본 연구에서는 패스워드 기반 사용자 인증의 약점을 극복하기 위한 2차 인증 방법으로 키스트로크 다이나믹스 기반 사용자 인증을 제안한다. 특히, 이 논문에서는 키스트로크 다이나믹스 기반 사용자 인증에 대한 선행 연구들에서 거의 다뤄지지 않았던 자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증을 연구하였으며, 선행 연구에서 수집하지 못한 변수를 사용하였고 제안하는 변수 조합 방법을 통해 인증 성능을 향상시켰다. 실험을 위해 100명의 피실험자들로부터 한국어와 영어의 2개 언어 각각에 대해 평균 17,000개 이상의 키스트로크를 수집하였다. 수집된 데이터를 활용한 실험을 통해 키 시퀀스를 사용하지 않은 방법과 키 시퀀스를 사용한 통계적 기반의 방법, 키 시퀀스를 사용한 기계학습 기반의 방법을 사용하여 각 인증 알고리즘의 성능을 측정해 비교하였다. 그 결과 본 연구에서 제안하는 변수 조합 방법과 키 시퀀스를 사용한 기계학습 기반 방법 중 가우시안 밀도 추정 알고리즘을 통해 학습과 테스트에 각 300개와 1000개의 키스트로크를 사용하여 한국어와 영어에서 각 0.59%, 0.29%의 최소 EER을 달성하였다.

표 목 차

Table 2.1 The studies of keystroke dynamics of free character strings ····· 4
Table 4.1 The summary of all scripts ····· 19
Table 4.2 The summary of preprocessed keystroke dynamics data ····· 21
Table 5.1 EERs(%) over all languages for each authentication algorithm and training-test length combinations ····· 26
Table 5.2 EERs(%) over all authentication algorithms and languages for each variable and training-test length combination ····· 32

그림목차

Fig. 3.1 The keystroke events during typing three key sequences ····· 7
Fig. 3.2 K-S statistic ····· 9
Fig. 3.3 C-M criterion ····· 10
Fig. 3.4 Example of ‘R’ and ‘A’ measure ····· 12
Fig. 3.5 Extracting features from input area ····· 13
Fig. 3.6 Example of the outlier detection based on Gaussian density estimation ····· 14
Fig. 3.7 Example of 1-SVM ····· 15
Fig. 3.8 Example of the outlier detection based on k-Means clustering ····· 16
Fig. 4.1 Web-based keystroke dynamics data collecting program ····· 18
Fig. 4.2 Frequency of each keycode from collected data ····· 20
Fig. 5.1 The boxplots of the EERs(%) over all training-test length combinations for each authentication algorithm ····· 27
Fig. 5.2 EERs(%) over all training-test length combinations for each authentication algorithm ····· 28
Fig. 5.3 EERs(%) for each language and authentication algorithm ····· 31
Fig. 5.4 Comparison among combined variable and other variables ····· 33
Fig. 5.5 Comparison among training data length and authentication algorithms ····· 34

Ⅰ. 서 론

오늘날, 인터넷 보급의 증가와 컴퓨터 기술의 발전에 따라 우리 삶의 많은 것들이 컴퓨터 네트워크 시스템에서 구현되어 사용되고 있다. 컴퓨터 네트워크 시스템에서 사용자 인증은 매우 중요한 문제이다[1-3]. 현재 컴퓨터 네트워크 시스템에서 패스워드 기반의 인증은 가장 흔한 사용자 인증 방법으로 사용되고 있다[1,3,4]. 패스워드 기반의 인증에서 사용자는 복잡한 패스워드를 사용할 것이 권장되며 웹사이트마다 서로 다른 패스워드를 사용하는 것이 안전하다. 하지만 사람들은 복잡한 패스워드를 기억하기 힘들어하기 때문에 간단한 패스워드를 선호하며 다양한 웹사이트에 대해 동일한 패스워드를 그대로 사용하곤 한다. 간단하고 약한 패스워드는 추측하기 쉬우며 사회공학적 방법 등으로 유추될 수 있다. 그리고 재사용된 패스워드의 유출을 통해 침입자는 사용자가 접속하는 모든 웹 사이트에서 올바른 사용자인 것처럼 거짓 인증이 가능하다[1,3,4].

패스워드 기반 인증의 취약점을 극복하기 위하여 2차 인증 수단으로써 생체 인증이 대안으로 제시되고 있다. 생체 인증은 패스워드와는 달리 유출이 어려우며 인증 당시에 인증된 사용자가 반드시 있어야만 인증이 가능한 장점이 있다[5]. 생체 인증에서는 사람마다 고유한 패턴을 가지는 DNA, 귀(귓바퀴의 연골 조직 구조), 얼굴, 안면 또는 손목 정맥 열상, 지문, 손과 손가락 모양, 홍채, 체취, 손금, 망막 등의 소유적 생체 정보(possessive biometrics)나 음성, 걸음걸이, 서명, 키스트로크 다이나믹스 등의 행위적 생체 정보(behavioral biometrics)가 사용될 수 있다. 그 중 DNA, 지문, 홍채, 손금, 망막은 상대적으로 높은 인식 정확도를 가지는 것으로 알려져 있다[6]. 그러나 이러한 소유적 생체 정보를 사용자 인증에 활용하기 위해서는 지문 인식 센서, 적외선 카메라, 홍채 인식 센서와 같은 인식 장치(하드웨어)의 추가적인 설치가 필수적이다[7].

따라서 본 연구에서는 다양한 생체 인증 기법 중 하드웨어의 추가 설치가 필요하지 않으면서 소프트웨어적으로 가장 용이하게 데이터 수집이 가능한 키스트로크 다이나믹스를 활용한 사용자 인증 방법론을 제안하고자 한다. 키스트로크 다이나믹스가 다른 생체 인증 기법보다 컴퓨터 네트워크 시스템에 적합한 이유는 다음과 같이 두 가지로 요약될 수 있다. 첫째, 키스트로크 다이나믹스 기반의 인증에서는 컴퓨터 시스템에서 누구나 사용하고 있는 입력 장치인 키보드를 인식 장치로서 사용해 추가 하드웨어 없이 사용자 인증이 가능하다.

둘째, 키스트로크 다이나믹스 기반의 사용자 인증은 지속 인증(continuous authentication)이 가능하다. 대부분의 생체 인증 기반 사용자 인증 연구는 한 번의 인증으로 사용자 인증 절차를 완료하는 ‘one shot’ 인증 방식을 사용한다. 이 방식은 시스템 내에서 한 번 인증이 이루어진 뒤 다른 사용자가 침입할 가능성이 있다(예: 세션 하이재킹). 반면, 키스트로크 다이나믹스 기반의 사용자 인증은 ‘one shot’ 인증을 완료한 사용자가 컴퓨터 시스템을 사용하며 키보드로 자유로운 텍스트를 타이핑하는 행위를 지속적으로 감시하여 지속 인증이 가능하게 하는 장점이 있다[8-10].

키스트로크 다이나믹스 기반 사용자 인증은 키보드 입력에 대한 시간 정보와 입력 키 조합을 사용자의 타이핑 패턴으로서 학습하여 인증을 요청하는 자의 신분을 확인한다[11]. 사용자의 타이핑 패턴을 인증에 활용하기 위해 사용자는 ‘고정된 텍스트의 입력’ 또는 ‘동적이고 자유로운 텍스트의 입력’을 학습 또는 검증에 사용하게 된다. 고정된 텍스트는 패스워드 입력 시 패스워드의 타이핑 패턴에 기반하여 인증이 이루어질 수 있으나 로그인할 때만 인증이 이루어지므로 앞에서 언급된 지속 인증이 불가능한 한계가 있다. 하지만 자유로운 텍스트를 인증에 사용한다면 고정된 텍스트를 기억하거나 명시적으로 입력할 필요가 없으며 로그인 이후에도 지속하여 침입자의 접근을 막을 수 있다[12]. 본 연구는 자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증 방법론을 대상으로 한다.

자유로운 문자열 입력에 대한 키스트로크 다이나믹스 데이터를 인증에 사용할 때는 비교 대상이 되는 학습 데이터와 테스트 데이터 간의 형태 및 길이가 고정되어 있지 않기 때문에 어떤 변수를 어떤 길이로 어떻게 추출하여 어떤 인증 알고리즘에 적용해야 할지에 대한 문제가 생긴다. 따라서 본 연구에서는 여러 종류의 인증 알고리즘과 키스트로크 데이터의 변수 추출 그리고 길이에 대한 실험을 통해 최적의 인증 조건을 찾고 인증 성능을 향상시키는 것을 목적으로 한다.

본 논문에서는 실험을 위해 100명의 한국인 피실험자들로부터 한국어와 영어에 대해 각각 평균 17,000 키스트로크 이상의 자유로운 텍스트 입력 데이터를 수집하였다. 그리고 한 사용자의 키스트로크 데이터만을 학습에 사용하는 일범주 분류 알고리즘을 적용하여 인증 모델을 구축하였다. 모델 구축에 사용되지 않은 99명의 사용자의 입력 데이터를 침입자로 가정하여 공격을 시도하는 시나리오를 통해 제안하는 방법으로 100명 각각에 대한 인증 모델을 변수별, 데이터 크기별, 언어별로 구분하여 그 인증 성능을 비교하였다. 또한 추출된 변수를 사용해 얻은 결과를 조합하는 변수 조합 기법을 적용할 경우 단일 변

수를 사용한 인증 모델에 비해 인증 성능이 향상되는 것을 확인하였다.

본 연구의 구성은 다음과 같다. 제 Ⅱ장에서는 자유로운 문자열 입력에 대한 키스트로크 기반 사용자 인증의 선행 연구를 살펴보고 Ⅲ장에서는 제안하는 인증 알고리즘과 데이터 추출 방법을 설명한다. Ⅳ장에서는 데이터 수집 및 인증 알고리즘을 적용 방법을 설명한 뒤 Ⅴ장에서 인증 성능 비교를 수행하였다. 마지막으로 제 Ⅵ장에서는 본 연구의 시사점과 향후 연구 방향을 제시하였다.

II. 문헌 연구

고정된 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증은 모든 사용자간 동일한 크기와 동일한 순서 및 동일한 문자열 입력에 대해 비교가 이루어진다. 하지만 자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증은 사용자 별로 데이터의 크기 및 각 문자열의 출현 빈도 및 출현 순서가 다르므로 각 입력에 대한 직접적인 비교가 어렵다. 따라서 키스트로크 다이나믹스 데이터의 특성 추출과 샘플링 방법의 난이도가 훨씬 높다고 할 수 있다.

이 장에서는 자유로운 문자열 입력에 대한 키스트로크 다이나믹스 관련 연구에 대해 사용자 간의 입력을 비교할 때 사용되는 비교 방법에 따라 2가지 분류로 나누어 소개하고자 한다. 동일한 문자열을 찾아 직접 비교하는 방법을 사용한 연구에는 Monrose와 Rubin[13], Gunetti와 Picardi[14]가 있었고 동일하지 않은 문자열로 비교를 시도한 연구로는 Ahmed와 Traore[9], Kang과 Cho[16]가 있었다. 각 연구에 대한 자세한 내용은 Table 2.1에 나타나 있다.

Table 2.1 The studies of keystroke dynamics of free character strings

비교 방법	연구	인증 알고리즘	사용 변수	피실험자 수	인증 성능
동일한 문자열 조합의 비교	Monrose & Rubin [13]	Euclidean distance, Non-weighted probability measure, Weighted probability measure	Duration, Latency	63	12.82% FRR (Weighted probability measure)
	Gunetti & Picardi [14]	'R' measure, 'A' measure, Combined measure	Latency	41	0.5% EER (Combined measure)
동일하지 않은 문자열 조합의 비교	Ahmed & Traore [9]	Neural Network	Duration, Interval	53	2.46% EER
	Kang & Cho [16]	The mean and variance equality test, Kolmogorov-Smirnov statistic, Cramer-von Mises criterion, Digraph Distance, 'R'&'A' measure, Gaussian density estimator, Parzen window density estimator, k-Nearest Neighbor, Support Vector Data Description	Latency	35	1.90% EER (R+A measure, PC keyboard)

Monrose와 Rubin[13]은 63명의 피실험자를 대상으로 11개월 이상 자유로운 문자열의 키스트로크 다이나믹스 데이터를 수집했다. 단일 알파벳(monograph)의 키 누름 시간(Duration)과 연속된 두 개(digraph) 또는 세 개의 알파벳(trigraph)의 키 간 입력 시간(Latency)을 변수로 추출한 뒤, 동일한 문자열에 대해 유클리드 거리를 비교하여 그 거리가 짧을수록 작을수록 같은 사용자일 가능성이 높다고 판단하였다. 또한 추출된 변수들의 평균과 표준편차 및 발생 빈도를 조합하여 두 비교 대상이 같을 확률(non-weighted probability)을 계산하였다. 뿐만 아니라 영어에서 'er', 'th', 're'과 같은 문자열 입력이 'qu'나 'ts'과 같은 문자열보다 더 많이 발생한다는 특성을 고려하여 발생 빈도를 가중치로 사용한 확률(weighted probability) 또한 인증에 사용하였다. 실험 결과 인증 정확도는 Weighted probability, Non-weighted probability, 유클리드 거리 순으로 높게 나타났으며 각 87.18%, 85.63%, 83.22%의 인증 정확도를 보였다.

Gunetti와 Picardi[14]는 41명의 피실험자로부터 6개월간 각 15개의 키스트로크 다이나믹스 데이터셋을 수집하였다. 이 데이터셋을 인증된 사용자로 가정하였고 다른 165명으로부터 각 1개의 데이터셋을 수집하여 침입자를 가정하였다. 각 데이터셋에는 키 입력을 시작한 시간(down-time)만이 수집되었고 n-graph의 Latency를 변수로서 추출하였다. 두 비교 대상 간 동일하게 발생한 n-graph의 Latency에 대해 그 상대적 순위를 비교하는 'R' Measure와 latency의 절대적 비교를 통한 'A' Measure를 인증 알고리즘으로 사용하였다. 사용자의 분류(classification, 모든 사용자의 레이블이 달린 데이터로 학습한 뒤 테스트 데이터의 레이블을 분류)와 인증(authentication, 모든 사용자의 레이블이 달린 데이터로 학습한 뒤 학습 데이터의 사용자 또는 새로운 사용자로부터 나온 테스트 데이터의 레이블로 분류하거나 학습 데이터에 존재하지 않은 사용자로 분류하는 것), 식별(identification, 한 사용자만의 데이터로 학습한 뒤 출처를 알 수 없는 테스트 데이터가 학습 데이터의 사용자와 일치하는지 아닌지를 판단)의 세 가지 상황을 가정하여 인증이 이루어졌다. 이 세 가지 중에서 식별(identification)이 세 가지 중 가장 어렵다는 것을 Ashbourn[15]을 통해 인용하였다. 참고로 본 연구에서 사용한 용어인 '인증(authentication)'은 Gunetti와 Picardi[14]에서 사용한 '식별(identification)'의 의미이다. 분류에서는 600번의 분류 시도를 통해 'R' Measure로 최소 0.83%의 분류 오류를, 'A' Measure로 최소 6.5%의 분류 오류를 보였다. 그리고 'R' Measure와 'A' Measure의 조합을 통해 최소 0.16%의 분류 오류를 달성하였다. 인증에서는 'R' Measure와 'A' Measure의 조합을 통해 최소 FAR

0.0173%(FRR 3.8333%)을 보였다. 마지막으로 식별에서는 ‘R’ Measure와 ‘A’ Measure의 조합을 통해 최소 EER 0.5%를 달성하였다.

Ahmed와 Traore[9]는 53명의 피실험자로부터 키스트로크 다이나믹스 데이터를 수집하여 monograph의 Duration과 digraph의 Interval을 특성으로 추출해 인증에 사용하였다. 기존 연구에서는 비교하고자 하는 두 데이터에 동시에 나타나는 n-graph만을 비교하여 인증이 이루어졌다. 하지만 이 연구에서는 동시에 나타나지 않는 digraph의 비교를 위해 존재하지 않는 digraph 조합의 시간 정보를 인공 신경망을 사용하여 예측하는 방법을 사용하였다. 이 방법을 통해 0.0152%의 FAR과 4.82%의 FRR, 2.46%의 EER을 달성하였다.

Kang과 Cho[16]는 다양한 입력 환경을 가정하여 PC 키보드뿐만 아니라 스타일러스 펜으로 눌러 입력되는 soft keyboard와 스마트폰의 터치 키보드(한 손 입력 및 양 손 입력)에 대한 자유로운 문자열의 키스트로크 데이터를 35명의 사용자로부터 수집하였다. 이 연구에서는 down-time만을 수집하여 Latency를 특성으로 사용하였다. 비교하고자 하는 두 데이터의 동일하지 않은 입력을 비교하기 위해 키보드를 세 개의 구간으로 나누었고 구간 별 digraph 조합을 통해 인증을 시도하였다. Gaussian density estimator, Parzen window density estimator, k-nearest neighbor detector(k-NN), support vector data description(SVDD)이 주요 인증 알고리즘으로 사용되었고 Parzen window density estimator에서 5.63% EER(PC 키보드)을 보였다. 그리고 키 시퀀스의 사용 여부, 언어, 데이터 크기에 대한 인증 성능이 12가지의 인증 알고리즘을 통해 비교되었으며 그 중 PC 키보드를 입력장치로 하는 R+A measure가 1.90% EER로 가장 우수한 인증 성능을 나타냈다.

Kang과 Cho[16]에서는 키보드의 입력 구간을 나누고 구간 별 조합을 사용하는 비교적 간단한 방법을 통해 두 데이터간 동시에 나타나지 않는 조합의 비교를 수행하여 낮은 EER을 달성하였다. 본 연구에서는 Kang과 Cho[16]에서 수집되지 않았던 키 입력 종료 시간(up-time)을 수집하여 새로운 변수로 사용하였으며 개별 변수들의 조합을 통해 Kang과 Cho[16]의 결과보다 우수한 인증 성능을 나타내고자 하였다.

Ⅲ. 연구 방법

키스트로크 다이나믹스는 사용자가 '어떤 키'를 '언제 눌렀고' '언제 뗐는지'에 대한 시간 정보를 다룬다. 한 사용자가 3개 키 시퀀스 'ABC'를 타이핑했을 때 키스트로크 다이나믹스는 Fig. 3.1과 같이 나타난다[12]. A를 누른 시각(down-time)은 T_{a1}이고 A를 뗀 시각(up-time)은 T_{a2}이다. 이를 바탕으로 다음과 같은 키 입력 패턴 변수를 추출할 수 있다. 첫째, 하나의 키 A에 대한 지속 시간(duration)은 T_{a2}-T_{a1}로 계산할 수 있으며 연속한 두 키 AB에 대해 앞 키 A를 뗀 뒤 뒷 키 B를 누른 시각 차이인 AB의 간격(Interval, up-down time)은 T_{b1}-T_{a2}로 계산할 수 있다. 뿐만 아니라 키 A와 키 B를 누른 시간의 간격(Latency, down-down time)은 T_{b1}-T_{a1}으로 구할 수 있으며 up-up time(T_{b2}-T_{a2}) 또는 total time(down-up time: T_{b2}-T_{a1})과 같은 시간 정보도 계산 가능하다[10,12,16].

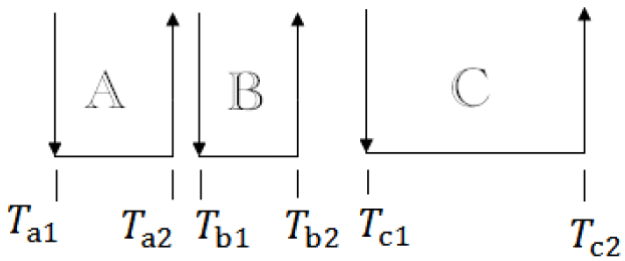

Fig. 3.1 The keystroke events during typing three key sequences

본 연구에서는 사용된 데이터 형태에 따라 세 가지 방법을 통해 인증을 수행했다. 첫 번째, '키 시퀀스 정보를 활용하지 않은 방법'은 어떤 키를 눌렀는지를 나타내는 keycode를 사용하지 않은 방법이다. 이 방법에서는 단일 키(monograph)의 Duration 시간 정보와 두 키의 조합(digraph)의 Interval, Latency 시간 정보를 사용하였다. 그리고 두 번째 방법은 '키 시퀀스 정보를 활용한 통계적 기반의 방법'으로 keycode를 사용하여 두 키의 조합에서 추출된 시간 정보의 비교가 이루어질 수 있도록 하였다. 이 방법에서는 Duration1(첫 번째 입력의 Duration), Duration2(두 번째 입력의 Duration), Latency, Interval의 네 가지 시간 정보를 인증에 사용하였다. 마지막 세 번째 방법은

‘키 시퀀스 정보를 활용한 기계학습 기반의 방법’이다. Monrose와 Rubin[13]과 Gunetti와 Picardi[14]의 연구에서는 동일한 문자열에 대해서만 비교가 이루어지기 때문에 동일한 문자열 입력이 발생하지 않으면 유사 정도를 구하기 힘든 한계점이 존재했다. 따라서 ‘키 시퀀스 정보를 활용한 기계학습 기반의 방법’에서는 각 키를 세 개의 입력 구간(L, R, S)으로 대체하는 방법을 사용하였다. 그 결과 두 키의 조합(digraph)에 대한 키 시퀀스의 조합을 줄여 더 많은 비교가 이루어질 수 있도록 하였다.

그리고 본 연구에서는 인증 성능 개선을 위해 개별 변수 사용 결과를 조합한 변수 조합 방법을 사용하였다. 이와 관련해서는 이 장의 4절에서 자세히 다루도록 하겠다.

1. 키 시퀀스 정보를 활용하지 않은 방법

키 시퀀스 정보를 활용하지 않은 방법에서는 단일 키의 Duration 시간 정보, 두 키의 조합에서 나타나는 Interval, Latency로 각각 나타낼 수 있는 경험적 분포 함수를 비교하는 두 가지 방법인 K-S 검정과 C-M 검정을 사용하여 인증된 사용자와 침입자의 데이터에서 나타나는 차이를 침입자 판단 지표(outlier score)로 사용하였다.

(1) K-S 검정(Kolmogorov-Smirnov statistic; K-S test)

키스트로크 학습 데이터세트를 K_R, 테스트 데이터세트를 K_T라고 하고 N_R와 N_T를 각각 학습 데이터세트와 테스트 데이터세트의 키스트로크 수라고 할 때 각 데이터세트에서 나타나는 시간 정보(monograph의 Duration, digraph의 Interval, Latency) 각각을 경험적 분포 함수로 식 (1)과 식 (2)로 정의할 수 있다.

$$F_{K_R}(x) = \frac{1}{N_R}\sum_{i=1}^{N_R} I(X_i \le x) \tag{1}$$

$$F_{K_T}(x) = \frac{1}{N_T}\sum_{j=1}^{N_T} I(X_j \le x) \tag{2}$$

$I(X_i \le x)$는 이를 만족하면 1을, 그렇지 않으면 0을 반환하는 지시 함수이다. 두 데이터세트의 경험적 분포 함수로 구한 K-S 통계량은 식(3)으로 정의할 수 있다.

$$D_{K_R}|_{K_T} = sup_x|F_{K_R} - F_{K_T}| \tag{3}$$

K-S 통계량은 두 데이터세트의 누적 분포에서 나타나는 차이의 최대값으로 설명될 수 있으며 이 통계량을 통해 두 데이터세트의 유사도를 측정할 수 있다. (Fig. 3.2[16] 참조.) 따라서 K-S 통계량이 작을수록 두 분포는 유사하다고 할 수 있다.

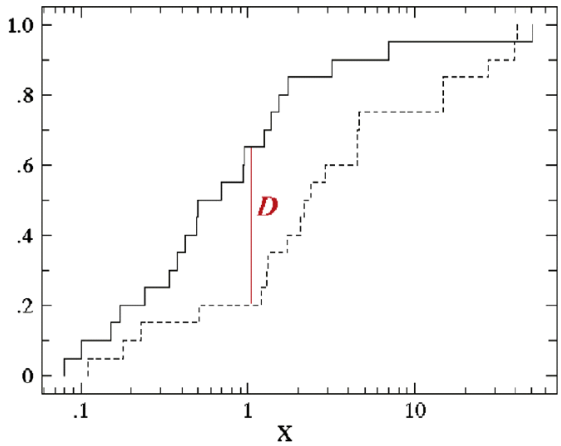

Fig. 3.2. K-S statistic

(2) C-M 검정(Cramér-von Mises criterion; C-M test)

C-M 검정은 K-S 검정과 마찬가지로 두 데이터세트로부터 나온 시간 정보에 대한 경험적 분포 함수를 비교하여 그 차이를 C-M 기준으로서 계산할 수 있다. 두 경험적 분포에서 나타나는 차이의 최대값으로 설명되었던 K-S 통계량과 달리 C-M 기준은 두 경험적 분포 함수의 모든 차이를 고려한다. (Fig. 3.3[16] 참조.) C-M 기준은 K-S 통계량과 마찬가지로 그 크기가 작을수록 두 분포는 유사하다고 할 수 있다. C-M 기준은 식 (4)로 정의할 수 있다.

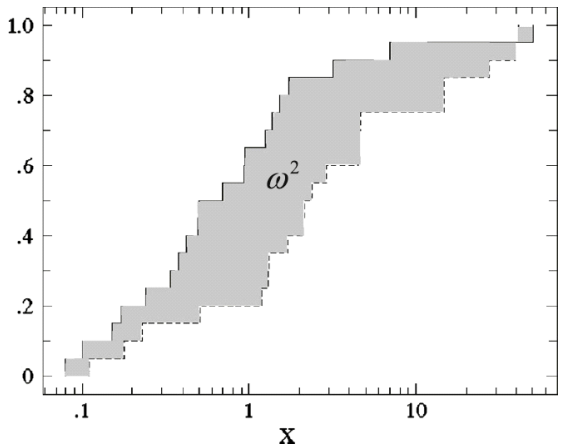

Fig. 3.3 C-M criterion

$$w^2 = \int_{-\infty}^{\infty} [F_{K_T}(x) - F_{K_R}(x)]^2 dx \tag{4}$$

2. 키 시퀀스 정보를 활용한 통계적 기반의 방법

K-S 통계량과 C-M 기준은 어떤 키를 눌렀는지를 나타내는 키 시퀀스 정보를 고려하지 않은 방법이다. 여기서는 키 시퀀스 정보를 활용한 통계적 기반의 방법을 설명한다. 이 방법에서 사용된 키 시퀀스 정보는 digraph로 나타난다. 예를 들어 한 사용자가 'by' 라는 텍스트를 타이핑한다고 가정한다면 가장 먼저 'b' 가 입력되고 'b' 에 대한 monograph의 Duration이 발생하게 된다. 그 뒤로 'y' 가 입력되면 'by' 라는 digraph 키 시퀀스에 대한 시간 조합(Interval, Latency)을 구할 수 있게 된다. (또한 'y' 에 대한 monograph의 Duration도 함께 나타난다.) 본 연구에서는 digraph에 대한 키 시퀀스 정보를 활용하였다.

하나의 digraph 키 시퀀스에서 4개의 특성을 추출할 수 있었다. 먼저, 하나의 digraph를 이루는 두 개의 monograph에 대한 Duration을 추출할 수 있었는데 첫 번째 monograph의 Duration을 Duration1, 두 번째 monograph의 Duration을 Duration2로 정의하였다. 그리고 digraph에서 나타나는 Interval과 Latency를 세 번째, 네 번째 특성으로서 추출하여 키 시퀀스 정보를 활용한 통계적 기반의 방법에서 사용할 수 있었다.

(1) ‘R’ 지표(R-measure)

R’ 지표는 비교하고자 하는 두 데이터세트에서 공통으로 나타난 키 시퀀스(digraph)의 시간 정보 순서를 비교하는 방법이다. 각 키 시퀀스 별로 시간 정보의 평균을 구한 뒤 이를 오름차순으로 정렬하면 그 순서에 대한 차이를 구할 수 있게 된다. ‘R’ 지표는 ‘순서의 차이 정도(degree of disorder)’를 ‘순서의 차이 정도 최대값(Max. degree of disorder)’로 나누어 구할 수 있다. ‘순서의 차이 정도 최대값(Max. degree of disorder)’은 키 시퀀스의 수를 n이라고 할 때 $n^2/2$(n이 짝수일 때) 또는 $(n^2-1)/2$(n이 홀수일 때)로 정의된다. ‘R’ 지표는 비교하고자 하는 두 데이터세트가 완전히 동일할 때 0이 되고 두 데이터세트에서 나타나는 키 시퀀스의 시간 정보 순서가 완전히 다를 때 1이 되므로, ‘R’ 지표가 작을수록 두 데이터세트를 유사하다고 할 수 있다. ‘R’지표의 예는 Fig. 3.4[14]의 (b)에 나타나 있다.

(2) ‘A’ 지표(A-measure)

‘R’ 지표는 시간 정보의 상대적인 순서를 고려할 수 있지만 절대적인 크기는 고려할 수 없는 한계가 있다. ‘A’ 지표는 이 단점을 극복할 수 있는 지표로 ‘R’ 지표와 마찬가지로 비교하고자 하는 두 데이터세트에서 공통으로 나타난 키 시퀀스별 시간 정보의 평균값을 사용한다. ‘A’ 지표는 비교할 두 시간 정보를 비교하여 크기가 큰 값과 작은 값의 비율을 계산하는데 두 시간 정보가 유사하다면 1에 가까울 것이고 그 차이가 클수록 비율은 커질 것이다. ‘A’ 지표는 모든 키 시퀀스에 대해, 계산된 비율이 컷오프 θ보다 작은 키 시퀀스의 수를 전체 키 시퀀스 수 n으로 나눈 것이다. ‘A’지표는 식 (5)와 식 (6)으로 정의할 수 있다. ‘A’지표의 예는 Fig. 3.4[14]의 (c)에 나타나 있다.

$$A_{count} = \sum_{k=1}^{n} I(|\frac{\max(x_i^k, x_j^k)}{\min(x_i^k, x_j^k)}| \le \theta) \tag{5}$$

$$'A'\text{지표} = \frac{A_{count}}{n} \tag{6}$$

E1: 0 **a** 180 **u** 440 **t** 670 **h** 890 **e** 1140 **n** 1260 **t** 1480 **i** 1630 **c** 1910 **a** 2010 **t** 2320 **i** 2600 **o** 2850 **n**

E2: 0 **t** 150 **h** 340 **e** 550 **o** 670 **r** 990 **e** 1230 **t** 1550 **i** 1770 **c** 1970 **a** 2100 **l**

(a) Keystroke dynamics data from two users for ‘R’ and ‘A’ measure

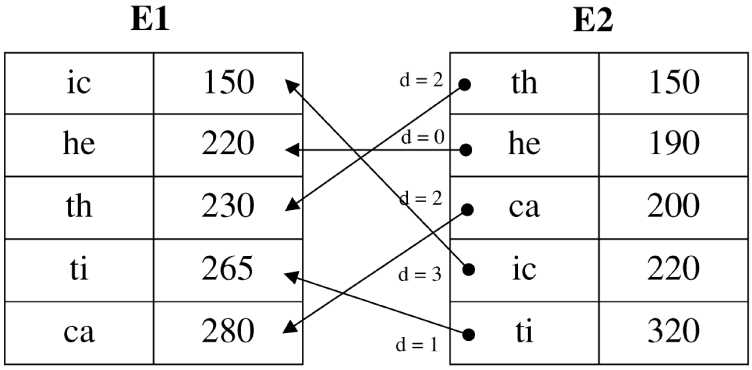

(b) Example of ‘R’ measure

E1		E2		
280	**ca**	200	(280/200 = 1.400)	
220	**he**	190	(220/190 = 1.157)	(similar pair)
150	**ic**	220	(220/150 = 1.466)	
230	**th**	150	(230/150 = 1.533)	
265	**ti**	320	(320/265 = 1.207)	(similar pair)

(c) Example of ‘A’ measure

Fig. 3.4 Example of ‘R’ and ‘A’ measures

본 연구에서는 컷오프 θ를 1.4로 정의하여 ‘A’ 지표를 구하였다. ‘A’ 지표는 컷오프 θ보다 작은 키 시퀀스의 수, 즉 유사한 것으로 판단되는 키 시퀀스의 수의 합을 전체 키 시퀀스 수로 나눈 값이기 때문에 ‘A’ 지표가 클수록 비교할 두 데이터세트는 유사한 것으로 볼 수 있다.

(3) ‘R+A’ 지표, ‘RA’ 지표(R+A meaure, RA measure)

‘R’ 지표와 ‘A’ 지표를 함께 사용하여 상대적 순서와 절대적인 수치 비교를 함께 할 수 있었다. 두 지표의 합인 ‘R+A’ 지표와 두 지표의 곱으로 나타나는 ‘RA’ 지표는 각각 식 (7)과 식 (8)로 정의된다.

$$'R+A'\text{지표} = 'R'\text{지표} + \alpha \times 'A'\text{지표} \tag{7}$$

$$'RA'\text{지표} = 'R'\text{지표} \times 'A'\text{지표} \tag{8}$$

‘R+A’ 지표에서는 결합 가중치 α를 정의해야 하는 문제가 있다. ‘RA’ 지표에서는 파라미터를 고려하지 않고 그 결합을 사용할 수 있다.

3. 키 시퀀스 정보를 활용한 기계학습 기반의 방법

키 시퀀스 정보를 활용한 통계 기반의 방법에서는 동일한 키 시퀀스(digraph)의 시간 정보를 비교하여 비교하고자 하는 두 데이터세트의 유사 정도를 구할 수 있었다. 하지만 동일한 키 시퀀스에 대해서만 비교가 이루어지므로 동일한 키 시퀀스가 발생하지 않으면 유사 정도를 구하기 힘든 한계점이 존재한다. 키 시퀀스 정보를 활용한 기계학습 기반의 방법에서는 이 한계를 해결하기 위해 각 키를 세 개의 입력 구간(L, R, S)으로 대체하였다. 대체된 입력 구간 정보는 Fig. 3.5와 같다. 그 결과 키 시퀀스(digraph)의 조합을 줄여 더 많은 비교가 이루어질 수 있도록 하였다.

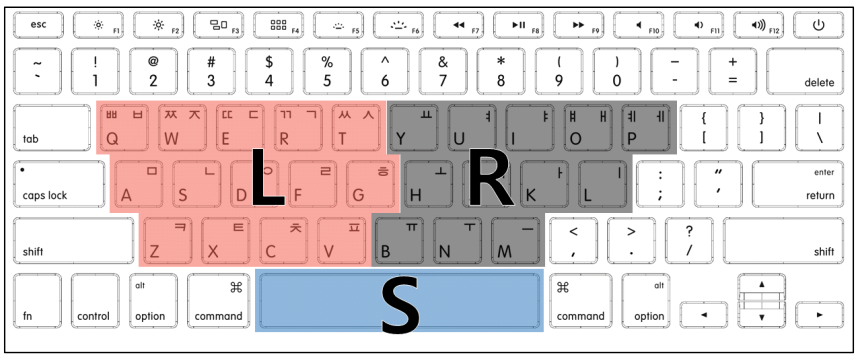

Fig. 3.5 Extracting features from input area

L, R, S의 세 개 구간에서 나타나는 digraph 키 시퀀스의 조합은 8가지로 나타난다(L-L, L-R, L-S, R-L, R-R, R-S, S-L, S-R). 이를 바탕으로 각 조합별 시간 정보의 평균을 구하여 8개의 변수를 만들 수 있는데, 본 연구에서는 digraph 키 시퀀스의 시간 정보에 대해 Duration1(첫 번째 입력의 Duration),

Duration2(두 번째 입력의 Duration), Latency, Interval 특성에 대해 각각 8개의 변수를 가진 8차원의 키스트로크 데이터셋으로 만들어 가우시안 밀도 추정(Gaussian density estimation)과 1-SVM(1-class Support Vector Machine), k-NN(k-Nearest Neighbor), k-평균 클러스터링(k-Means clustering)의 네 가지 인증 알고리즘을 적용하였다.

(1) 가우시안 밀도 추정(Gaussian Density Estimation; Gauss)

한 사용자의 키스트로크 데이터세트를 가우스 분포로 나타내어 평균 벡터 μ와 공분산 행렬 Σ를 추정할 수 있다. 그 식은 식 (9)로 나타낼 수 있다.

$$p(x) = \frac{1}{(2\pi)^{d/2}|\sum|^{1/2}} exp[-\frac{1}{2}(x-\mu)^T \sum^{-1} (x-\mu)] \tag{9}$$

식 (9)를 사용하여 비교 대상이 되는 데이터세트의 정규분포확률값을 구할 수 있는데 그 값이 클수록 정상 데이터, 작을수록 침입자 데이터로 판단할 수 있다. (정상 데이터와 침입자 데이터를 판단하는 예는 Fig. 3.6[17]에 나타나 있다.)

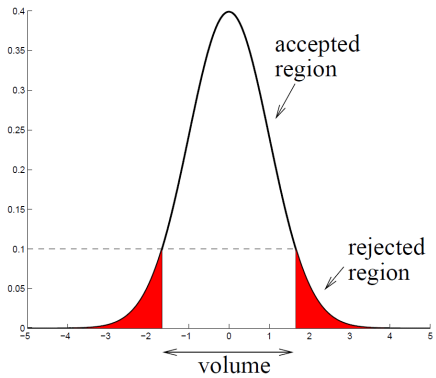

Fig. 3.6 Example of the outlier detection based on Gaussian density estimation

(2) 1-SVM(1 class Support Vector Machine)

1-SVM은 정상 데이터로만 이루어진 데이터세트로 학습하여 고차원의 공간

(feature space)에서 정상치와 이상치를 분리하는 초평면과 이상치와의 거리(margin)를 최대화하는 초평면 w를 찾는 알고리즘이다. (Fig. 3.7[18] 참조.) 1-SVM의 목적 함수와 제약식은 각각 식 (10)과 식 (11)와 같다.

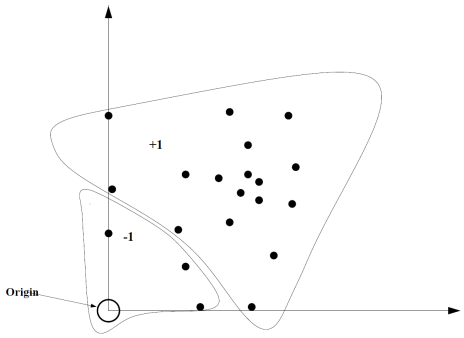

Fig. 3.7 Example of 1-SVM(The nearer from the origin, the nearer to outliers)

$$\min \frac{1}{2}\|w\|^2 - p + \frac{1}{vn^+}\sum_{x_i \in X^+} \xi_i^+ \tag{10}$$

$$s.t \;\; w^T \Phi(X_i) \geq p - \xi_i^+, \;\; \xi_i^+ \geq 0 \tag{11}$$

초평면 w와 각 데이터와의 거리를 구한 뒤 그 거리가 가까울수록 정상치로 판단하였다.

(3) k-NN(k-Nearest Neighbor)

k-NN은 분류되지 않은 데이터가 새로이 유입됐을 때, 범주가 알려진 데이터셋을 참조하여 그와 유사한 개체들을 선택한 뒤 유사한 개체들의 정보를 사용하여 데이터를 분류하는 방법이다. k-NN기반의 이상치 탐지에서는 몇 개의 유사한 개체들을 선택할 지에 대한 최적의 근접 이웃의 수 k를 찾아야 하는 문제가 있다. 본 연구에서는 참조 데이터가 정상치로만 이루어진 데이터셋이므로, 정상 또는 침입자로 분류되지 않은 데이터를 평가할 때 k개의 근접 이웃을 찾은 뒤 평가할 데이터와 근접 이웃들 간의 거리 평균을 평가 기준으로 사용하였다. 거리 평균이 작을수록 인증된 사용자로, 거리 평균이 클수록 침입자로 판단하였다.

(4) K-평균 군집화(k-Means Clustering; KMC)

K-평균 군집화는 군집 내부 거리(intra-cluster distance)를 최소화하고 군집 사이 거리(inter-cluster distance)를 최대화하는 K개의 군집 중심(cluster center)을 찾는 것을 목적으로 하는 알고리즘이다. 본 연구에서는 학습 데이터셋으로 K개의 클러스터를 판별한 뒤 테스트 데이터셋의 데이터와 각 클러스터 중심과의 거리를 구하여 가장 가까운 거리를 이상치 점수로 사용하였다. (Fig. 3.8 참조) 이를 통하여 가장 가까운 클러스터 중심과의 거리가 가까울수록 인증된 사용자로, 거리가 멀수록 침입자로 판단할 수 있다.

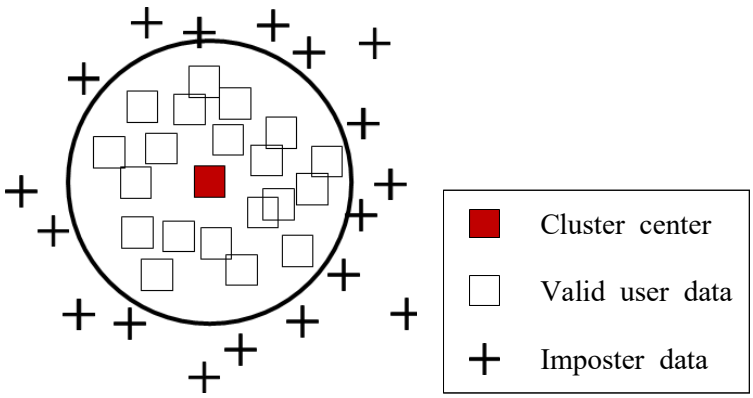

Fig. 3.8 Example of the outlier detection based on k-Means clustering

4. 변수 조합 방법

앞 절에서 소개된 인증 방법들을 통해 테스트 데이터에 대해 침입자 판단 지표(outlier score)를 계산할 수 있다. 입력 구간에 대한 digraph의 Duration1, Duration2, Interval, Latency 중 하나로 만든 시간 정보를 입력 데이터로 사용하였고 테스트 데이터에 대한 침입자 판단 지표의 값이 크면 클수록 침입자로 그렇지 않으면 인증된 사용자로 판단할 수 있었다.

본 연구에서는 개별 변수를 사용하는 한편 각 인증 알고리즘에서 네 가지의 개별 변수 집합을 기반으로 계산된 침입자 판단 지표를 조합하는 변수 조합 기법을 사용하였다. 제안된 방법에서는 네 개의 변수 집합별로 구한 침입자 판단 지표의 기하 평균을 침입자 판단 지표로 사용한다. 사용된 변수 집합의

개수를 n이라고 할 때 변수 조합 방법에서 침입자 판단 지표를 구하는 방법은 식 (12)와 같다.

$$Combine(x_i) = (\prod_{k=1}^{n} f_k(x_i))^{1/n} \tag{12}$$

Ⅳ. 실험 설계

본 연구에서는 피실험자들의 키스트로크 입력 데이터를 수집하여 인증된 사용자와 침입자로 가장하여 사용하였다. 그리고 사용자 인증을 위해 키 시퀀스 정보를 사용하지 않은 방법, 키 시퀀스 정보를 사용한 통계적 기반의 방법 그리고 키 시퀀스 정보를 사용한 기계학습 기반의 방법의 세 가지 사용자 인증 방법을 통해 실험을 실시하였고 성능 평가 지표로 EER(Equal Error Rate)를 사용하여 인증 성능을 평가하였다. 이 장에서는 데이터 수집 방법과 인증 알고리즘 적용 방법 그리고 성능 평가 지표 EER에 대해 설명하였다.

1. 데이터 수집

본 연구에서는 100명의 한국인 대학생, 대학원생이 피실험자로 실험에 참여하였다. 실험을 위해 웹 기반의 키스트로크 수집 프로그램을 직접 개발하여 사용하였으며, 피실험자들은 화면에 출력된 스크립트를 보고 그 내용을 키보드로 타이핑하는 방식으로 실험에 참여하였다. (Fig. 4.1 참조.)

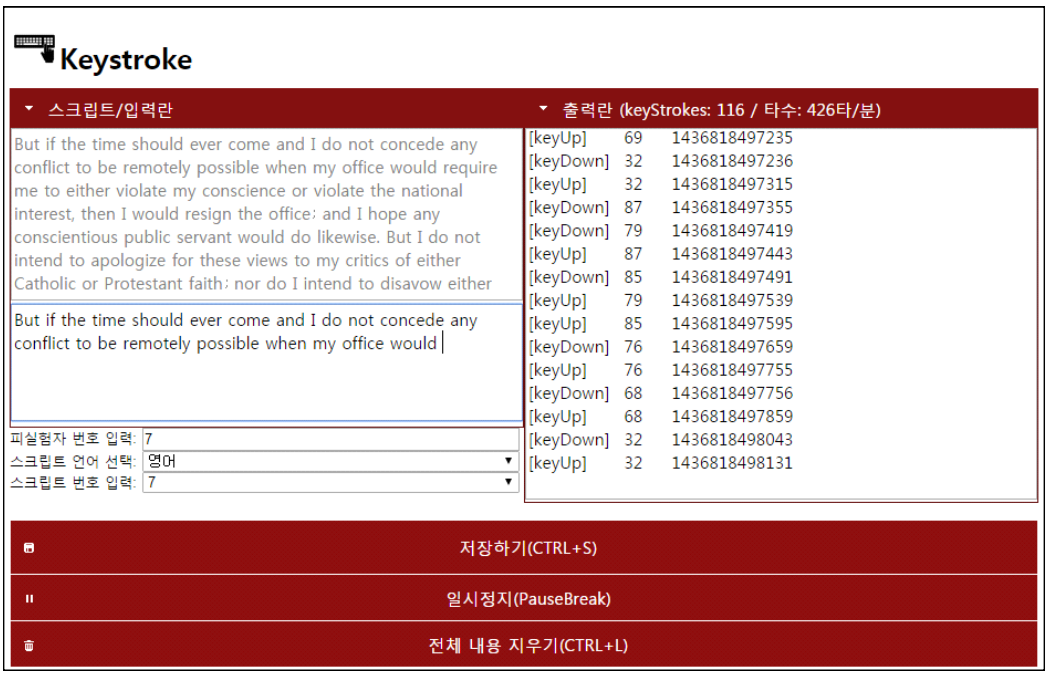

Fig. 4.1 Web-based keystroke dynamics data collecting program

자유로운 텍스트를 가정하기 위하여 피실험자 별로 서로 다른 내용의 스크립트가 주어졌고 두 가지 언어에 대한 인증 성능을 비교하기 위하여 스크립트는 영문으로만 이루어진 영어 스크립트 1부와 한글로만 이루어진 한국어 스크립트 1부가 제공되었다. 따라서 피실험자 한 명당 영어와 한국어 각 1세트의 키스트로크 다이나믹스 데이터를 수집할 수 있었다. 스크립트와 수집된 키스트로크 다이나믹스 데이터의 요약 정보는 Table 4.1과 Fig. 4.2에 나타나 있다.

Table 4.1 The summary of all scripts (Unit: word)

Language	Average	Median	Standard deviation	Max.	Min.
English	14988.2	14998	158.3	15586	14326
Korean	7493.7	7493	45.8	7598	7160

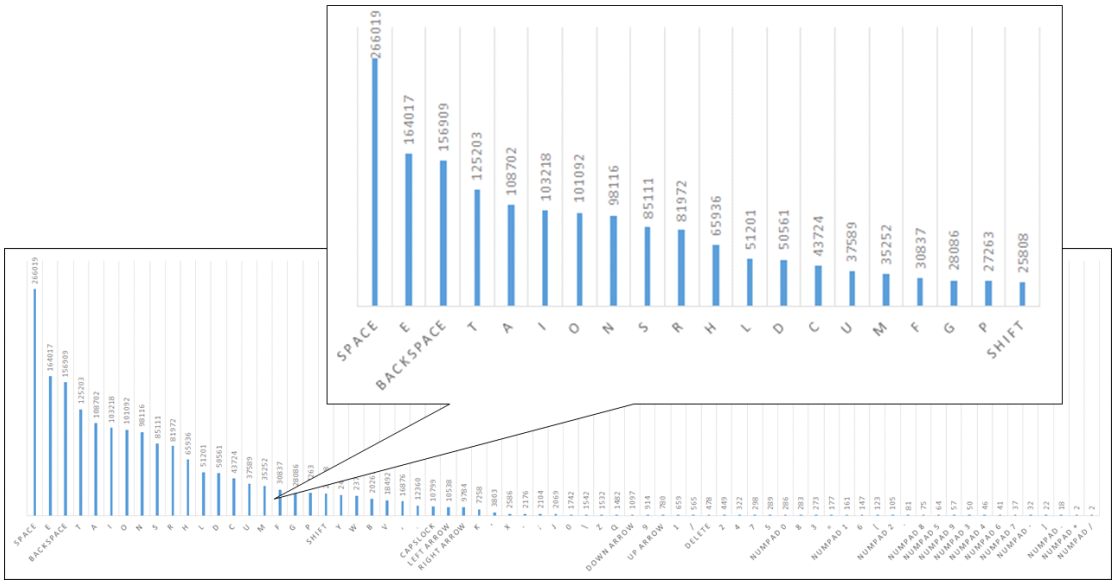

(a) English

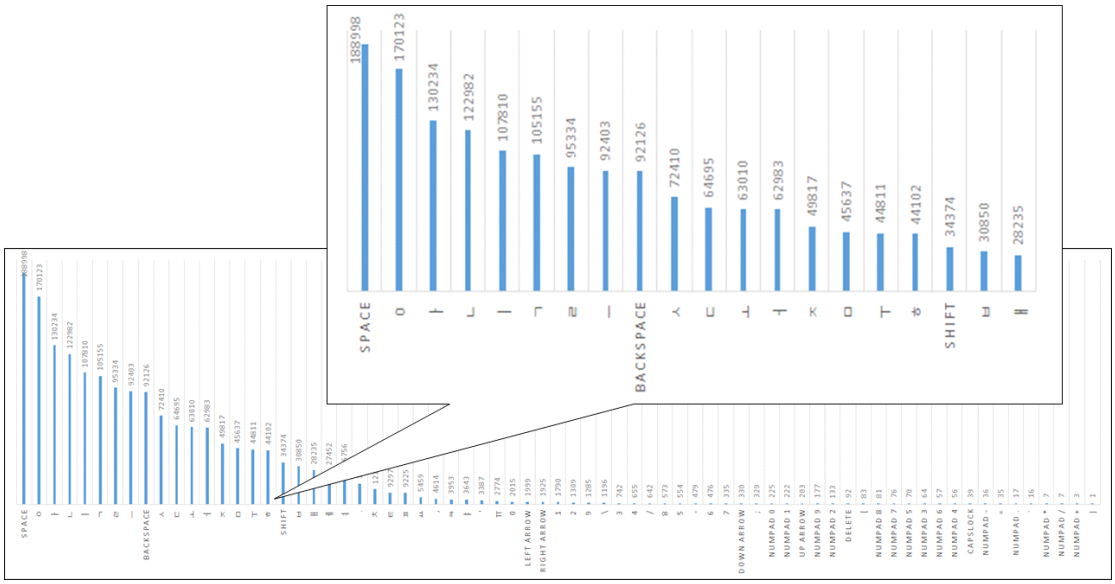

(b) Korean

Fig. 4.2 Frequency of each keycode from collected data
(keycodes replaced as with relevant characters)

실험을 통해 얻은 데이터는 keycode, down-time과 up-time으로 구성된다. keycode는 입력된 키의 식별 번호, down-time은 키가 눌린 시각이며 up-time은 눌린 키가 떼어진 시각이다. 시간 정보는 1/1000초(millisecond) 단위로 수집되었다.

수집된 데이터에서 추출된 변수에 대해 Duration은 10ms~1,000ms, Interval은 -200ms~2,000ms의 범위 내 데이터만을 사용하였으며 시간적으로 초반부에 수집된 100개의 키스트로크 데이터는 안정화를 위해 제거하였다. 그리고 본 연구에서는 수집된 모든 데이터를 사용하는 대신 언어적 특성으로 비교가 가능한 영문 알파벳과 한글 자/모음 그리고 빈도가 높은 Space만이 사용되었다. 전처리 이후 키스트로크 다이나믹스 데이터의 요약 정보는 Table 4.2와 같다.

Table 4.2 The summary of preprocessed keystroke dynamics data (Unit: keystroke)

Language	Average	Median	Standard deviation	Max.	Min.
English	17885.4	17834	1345.5	22170	14790
Korean	17468.3	17436	959.6	20829	13322

2. 인증 방법

본 실험에서는 인증 모델을 학습하기 위해 인증된 사용자의 데이터만을 보유한 상황을 가정하는 일범주 분류(one-class classification) 상황 하에서 인증된 사용자의 데이터 일부를 학습 데이터로 이용하여 인증 모델을 구축하였다. 인증 모델을 평가하기 위해 인증된 사용자의 데이터 중 학습 데이터로 사용되지 않은 부분을 테스트 데이터(분류 레이블: 인증된 사용자)로 사용하였고 다른 사용자 99명 모두의 데이터 일부를 침입자로 가정하여 테스트 데이터(분류 레이블: 침입자)로 사용하였다.

사용된 키스트로크 다이나믹스 데이터의 언어와 데이터 크기에 따른 인증 성능을 알아보기 위해 언어 종류와 데이터 크기를 다르게 하여 데이터 샘플링을 실시하였다. 크기의 경우 학습 데이터의 크기는 100, 300, 500, 1000개의 키스트로크를 사용하는 4가지 경우, 테스트 데이터의 크기는 100, 300, 500, 1000

개 키스트로크를 사용하는 4가지 경우를 가정하였다.

인증 실험은 인증 알고리즘, 학습 데이터 크기, 테스트 데이터 크기, 사용 변수의 모든 경우에 대해 이루어졌다. 그리고 제안된 세 가지 인증 방법에 대해 각각 서로 다른 샘플링이 이루어졌다.

(1) 키 시퀀스 정보를 사용하지 않은 방법

K-S 검정과 C-M 검정의 학습 데이터를 위해 한 사용자의 초반부 데이터를 정해진 크기로 추출하여 학습 데이터 1세트를 구성하였다. 그리고 정상 사용자의 정상 사용 99회를 가정하기 위하여 사용자의 데이터 중 학습 데이터의 구성에 사용되지 않은 데이터를 정해진 크기로 임의 추출하여 99세트의 테스트 데이터(클래스: 인증된 사용자)를 구성하였다. 그리고 침입자의 공격 99회를 가정하기 위해 다른 사용자 99명의 데이터를 각각 임의 추출하여 99세트의 테스트 데이터(클래스: 침입자)를 구성하였다. 198세트의 테스트 데이터에 대해 각각의 침입자 판단 지표를 구하였다.

(2) 키 시퀀스 정보를 사용한 통계적 기반의 방법

(1)과 마찬가지로 한 사용자의 초반부 데이터를 정해진 크기로 추출하여 학습 데이터 1세트를 구성하였다. 그리고 정상 사용자의 정상 사용 99회를 가정한 99세트의 테스트 데이터와 침입자의 공격 99회를 가정한 99세트의 테스트 데이터까지 총 198세트의 테스트 데이터를 학습 데이터와 비교하여 각 테스트 데이터세트에 대해 침입자 판단 지표를 구하였다.

(3) 키 시퀀스 정보를 사용한 기계학습 기반의 방법

한 사용자의 키스트로크 다이나믹스 데이터를 시간 순으로 정렬한 뒤 연속된 일부를 정해진 크기로 추출하여 학습 데이터를 구성하였고, 학습 데이터로 사용되지 않은 나머지 중 연속된 일부를 정해진 크기로 추출해 정상 및 침입자의 테스트 데이터로 사용하였다. 1열의 인스턴스가 1회의 정상 사용 또는 공격을 가정하는 시나리오를 위해 한 사용자의 데이터를 정해진 크기로 나누어 99개의 데이터셋을 만든 뒤 각 데이터셋의 모든 열에 대한 평균을 구하여 최종적으로 99개의 열을 가진 1개의 데이터셋을 만들었다. 이는 학습 데이터로 사용된다. 사용자의 데이터 중 학습 데이터로 사용되지 않은 부분을 사용하여

99개의 열을 가진 1개의 테스트 데이터셋도 같은 방법으로 만들 수 있으며 정상 사용자의 정상 사용 99회로 사용된다. 그리고 다른 사용자 99명이 가진 학습 데이터셋에서 각 1열씩 임의 추출하여 99열로 구성된 테스트 데이터셋을 구성할 수 있다. 이는 침입자의 99회 공격을 가정한 테스트 데이터로 사용된다. 학습 데이터로 학습한 인증 알고리즘으로 전체 테스트 데이터 198열에 대해 각각 침입자 판단 지표를 구할 수 있다.

3. 성능 평가 지표

제 Ⅲ장에서 설명한 인증 방법과 2절에서 언급된 데이터 샘플링 방법을 통해 99회의 정상 사용과 99회의 공격을 가정한 198세트 또는 198열의 테스트 데이터에 대해 각각 침입자 판단 지표를 구할 수 있다. 침입자 판단 지표를 기준으로 테스트 데이터셋을 오름차순 정렬했을 때, 순서상 위쪽에 위치하며 침입자 판단 지표가 상대적으로 낮은 데이터는 정상 사용으로 볼 수 있다. 반면 아래쪽에 정렬되어 침입자 판단 지표가 상대적으로 높은 데이터는 침입자의 공격으로 판단할 수 있다. 하지만 이는 상대적 기준으로, 어디까지가 정상 사용이고 어디까지가 공격인지를 판단할 수 없는 문제가 발생한다.

이 문제를 해결하기 위해 정상 사용과 공격의 경계를 cut-off로 하여 설정할 필요가 있는데, cut-off를 너무 엄격하게 설정하게 되면 적은 수의 테스트 데이터만이 정상 사용으로 판단된다. 극단적으로, 198개의 테스트 데이터 중 단 하나의 데이터만을 정상 사용으로 판단하도록 cut-off를 설정한다면 침입자가 정상 사용자로 잘못 판단될 확률은 1/99 또는 0으로 아주 작은 확률이 나온다. 하지만 정상 사용자가 침입자로 잘못 판단될 확률은 1 또는 98/99로 1에 가깝다. cut-off를 낮추면 정상 사용자가 침입자로 잘못 판단될 확률은 감소하지만 침입자가 정상 사용자로 잘못 판단될 확률은 반비례하여 증가한다.

침입자가 정상 사용자로 잘못 판단되는 오류율을 False acceptance rate(FAR), 정상 사용자가 침입자로 잘못 판단되는 오류율을 False rejection rate(FRR)라고 한다. 서로 반비례 관계인 두 지표는 인증 방법의 성능을 측정하는데 사용될 수 있지만 cut-off의 설정에 따라 크게 영향을 받게 된다. 따라서 본 연구에서는 cut-off에 자유로운 지표인 Equal error rate(EER)를 인증 방법의 성능 평가 지표로 사용한다. EER은 모든 cut-off에 대한 FAR과 FRR의 결과에 대해 두 성능 지표의 값이 같아지거나 그 거리가 가장 가까운 지점

에서의 FAR과 FRR의 평균을 의미한다. FAR 또는 FRR 한 쪽에만 유리하도록 cut-off를 설정할 경우 EER이 증가하며, FAR과 FRR을 모두 낮춰야 EER이 감소한다[19].

Ⅴ. 실험 결과

자유로운 문자열 입력에 대한 키스트로크 기반 사용자 인증은 인증 알고리즘, 학습 데이터와 테스트 데이터 크기, 키스트로크 데이터 언어, 사용된 변수에 따라 인증 성능이 다르게 나타났다. 이 장에서는 위에서 언급된 각 통제 변인별로 어떤 상황에서 가장 좋은 인증 성능을 나타내는지 실험 결과를 설명하였다. 그리고 본 연구에서 제안한 변수 조합 방법과 다른 변수 사용과의 실험 결과를 비교하였다.

1. 알고리즘에 따른 인증 성능

본 연구에 사용된 모든 알고리즘의 인증 성능을 비교하기 위해 알고리즘별 피실험자 100명의 평균 EER을 데이터 크기에 따라 Table 5.1에 나타내었다. 데이터 크기별로 가장 낮은 평균 EER은 굵은 글씨로 강조되어 있다.

학습 데이터의 크기가 1000 키스트로크이고 테스트 데이터의 크기가 100 키스트로크인 상황을 제외한 모든 상황에서 키 시퀀스를 사용한 기계학습 기반의 방법의 인증 성능이 가장 좋은 것으로 나타났다.

학습 데이터의 크기가 500 키스트로크 이하일 때 거의 모든 경우에서 키 시퀀스를 활용한 기계학습 기반의 방법인 가우시안 밀도 추정이 가장 좋은 인증 성능을 보였다. 그리고 학습 데이터가 가장 큰 1000 키스트로크일 때는 키 시퀀스를 활용한 통계 기반의 방법인 R+A measure와 키 시퀀스를 활용한 기계학습 기반 방법인 1-SVM과 k-NN이 가장 좋은 인증 성능을 보였다.

각 알고리즘의 성능 편차는 언어에 따라 다르게 나타났다. 언어에 대한 알고리즘별 평균 EER의 비교는 Fig. 5.1에 나타나 있다.

Table 5.1 EERs(%) over all languages for each authentication algorithm and training-test length combinations

N. Trn.	N. Test	K-S test	C-M test	R-measure	A-measure	R+A measure	RA measure	Gauss	1-SVM	k-NN	KMC
100	100	22.01	24.35	27.52	25.91	22.68	22.89	**13.31**	13.61	14.82	14.40
	300	20.13	22.04	21.16	21.53	17.03	17.11	**6.62**	7.62	9.05	9.15
	500	19.05	21.22	18.18	19.92	15.04	15.05	**4.57**	5.73	7.37	7.79
	1000	17.98	20.17	14.78	17.87	12.35	12.36	**2.71**	3.83	5.62	6.31
300	100	20.28	22.06	21.58	21.34	17.18	17.28	14.57	**13.84**	14.65	14.66
	300	17.18	19.40	14.94	17.06	11.95	11.93	**7.19**	7.84	7.99	8.02
	500	16.27	18.30	12.14	15.10	9.84	9.78	**4.98**	5.84	5.95	6.09
	1000	14.86	17.05	8.92	12.86	7.44	7.42	**2.86**	3.84	3.87	4.22
500	100	19.35	21.33	19.59	19.81	15.35	15.47	15.58	**14.03**	14.87	14.96
	300	16.40	18.28	12.95	15.29	10.26	10.28	8.04	**7.88**	8.08	8.20
	500	14.93	17.14	10.29	13.29	8.22	8.21	**5.69**	5.91	5.90	6.11
	1000	13.36	15.89	7.41	11.02	6.02	6.06	**3.33**	3.93	3.75	4.07
1000	100	17.99	19.64	16.77	17.98	**13.06**	13.13	17.75	14.48	15.12	15.19
	300	14.33	16.44	10.89	13.54	8.51	8.53	9.59	**8.24**	8.28	8.43
	500	12.95	15.21	8.39	11.47	6.57	6.58	6.98	6.22	**6.02**	6.18
	1000	11.36	13.72	5.61	9.09	4.54	4.58	4.34	4.07	**3.82**	4.00
Average EER		16.78	18.89	14.44	16.44	11.63	11.67	8.01	**7.93**	8.45	8.61

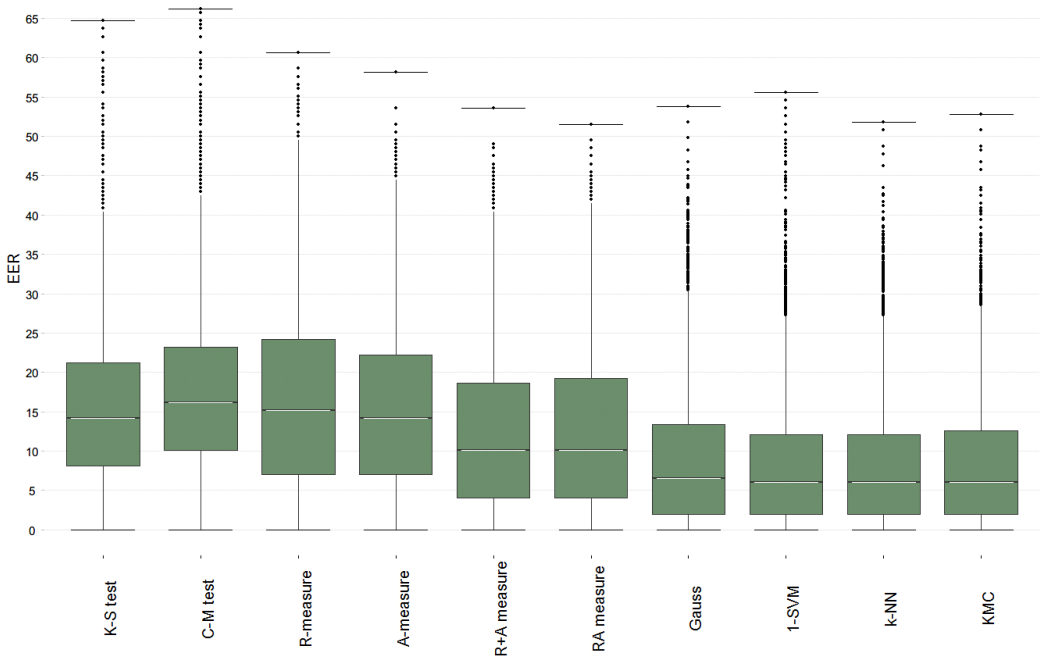

(a) English

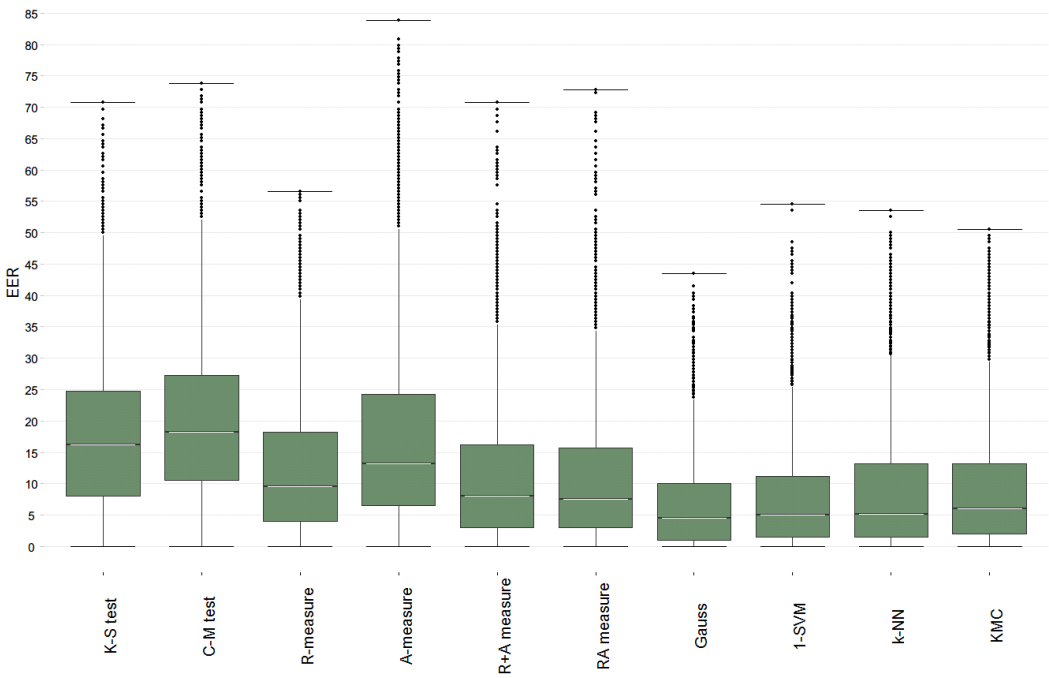

(b) Korean

Fig. 5.1 The boxplots of the EERs(%) over all training-test length combinations for each authentication algorithm

2. 사용 데이터 크기에 따른 인증 성능

일부 알고리즘을 제외하고 학습 데이터의 크기가 클수록 인증 성능은 대체로 좋아졌고, 모든 알고리즘에서 테스트 데이터의 크기가 클수록 더 좋은 인증 성능을 보였다. 학습 데이터의 크기가 100, 300, 500, 1000 키스트로크일 때 모든 알고리즘에 대한 평균 EER은 각 14.78%, 11.97%, 11.18%, 10.29%로 나타났다. 테스트 데이터의 크기가 100, 300, 500, 1000 키스트로크일 때 평균 EER은 각 17.63%, 12.20%, 10.25%, 8.13%로 나타나 테스트 데이터의 크기에 따라 평균 EER이 최대 50% 가량 감소하였다.

학습 데이터의 크기와 테스트 데이터의 크기가 모두 100 키스트로크로 가장 적은 데이터를 사용했을 때 모든 언어, 변수, 알고리즘에 대한 평균 EER은 20.02%로 나타났고, 가장 큰 데이터 크기인 1000 키스트로크를 사용한 상황에서는 평균 EER이 6.26%로 나타났다.

학습 데이터와 테스트 데이터 크기의 모든 조합에 대한 알고리즘 별 평균 EER을 비교한 그래프는 Fig 5.2에 나타나 있다.

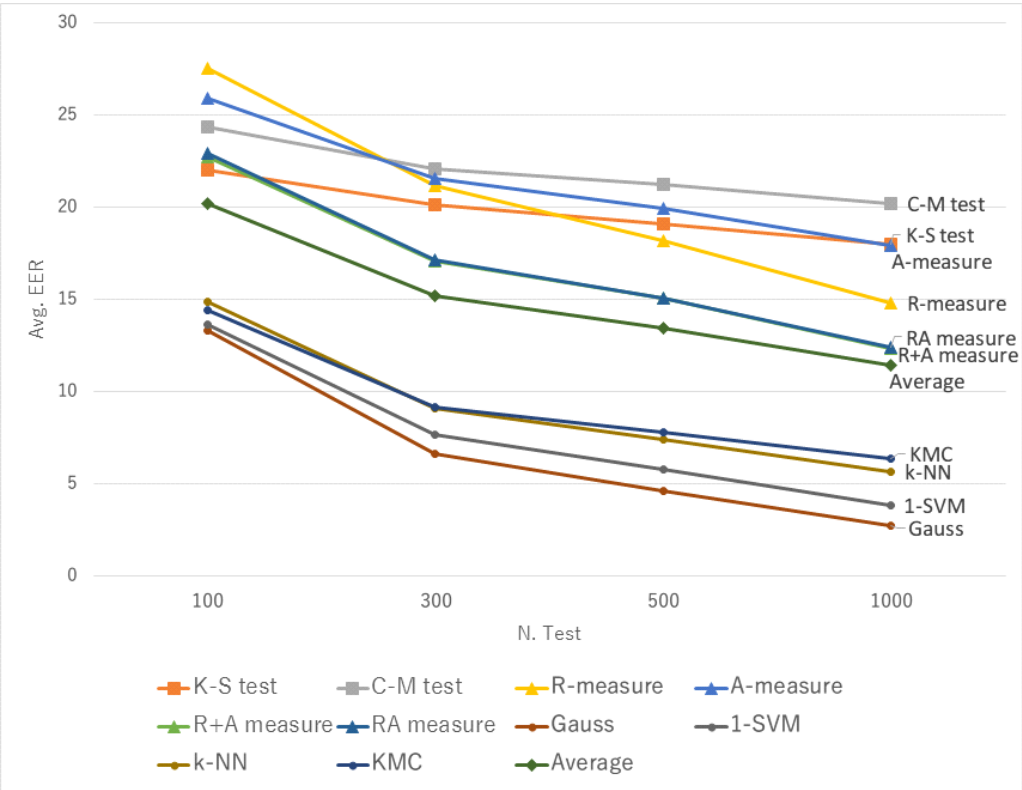

(a) Trn. data size: 100

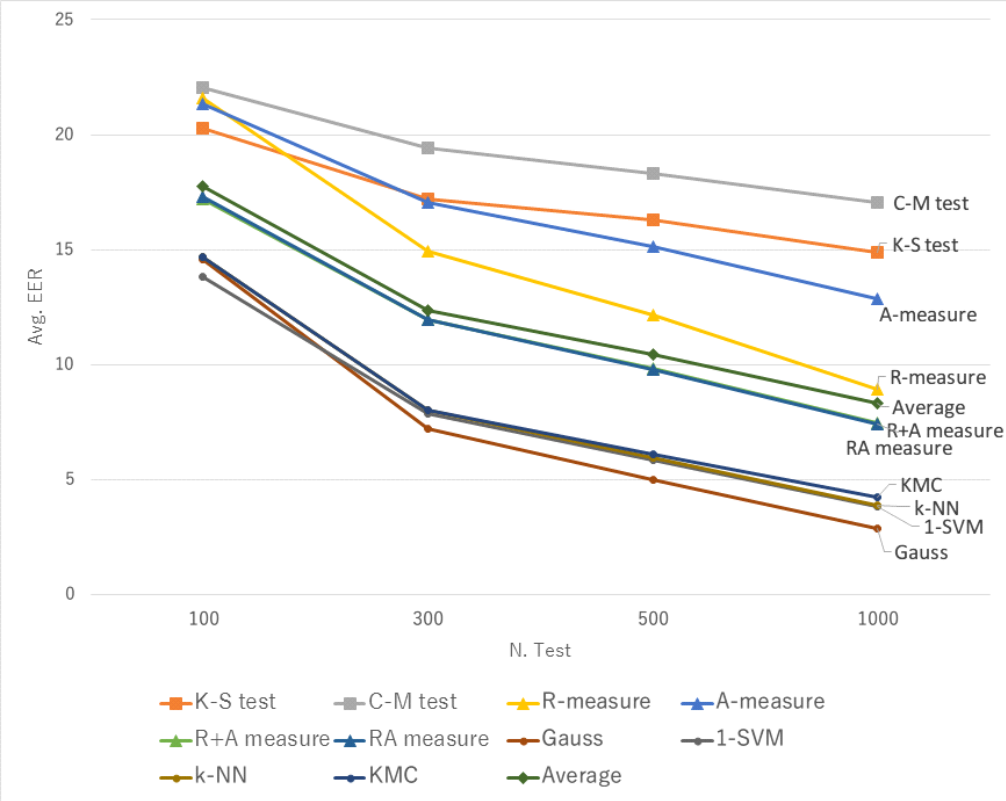

(b) Trn. data size: 300

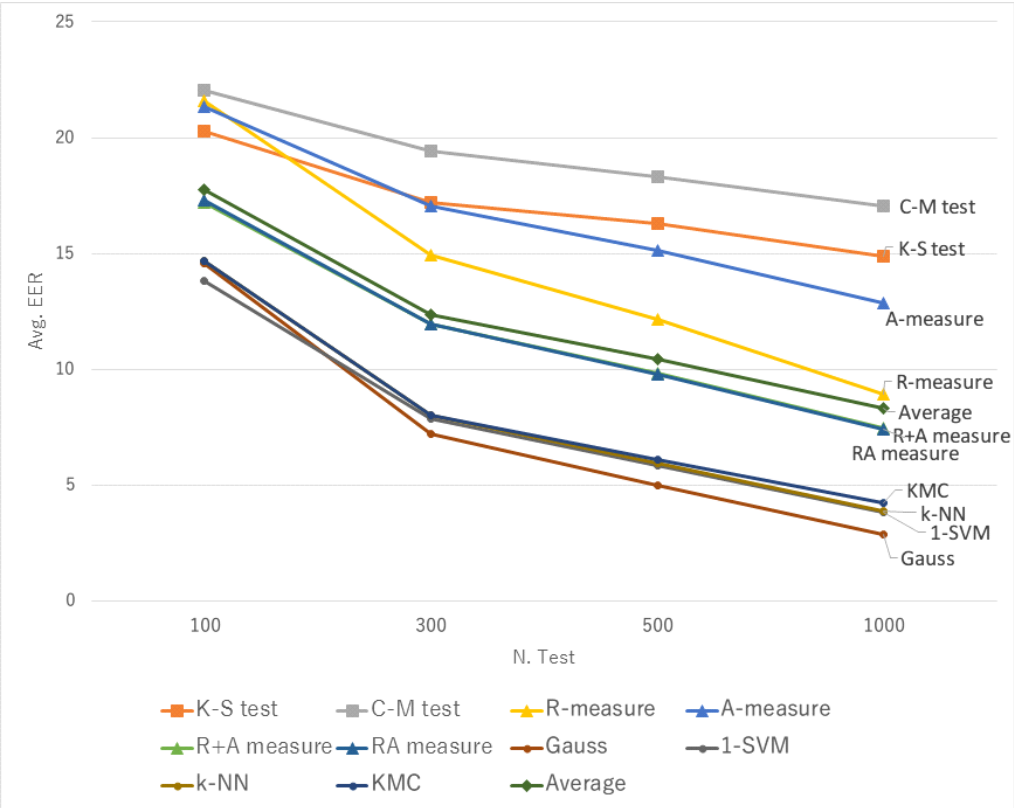

(c) Trn. data size: 500

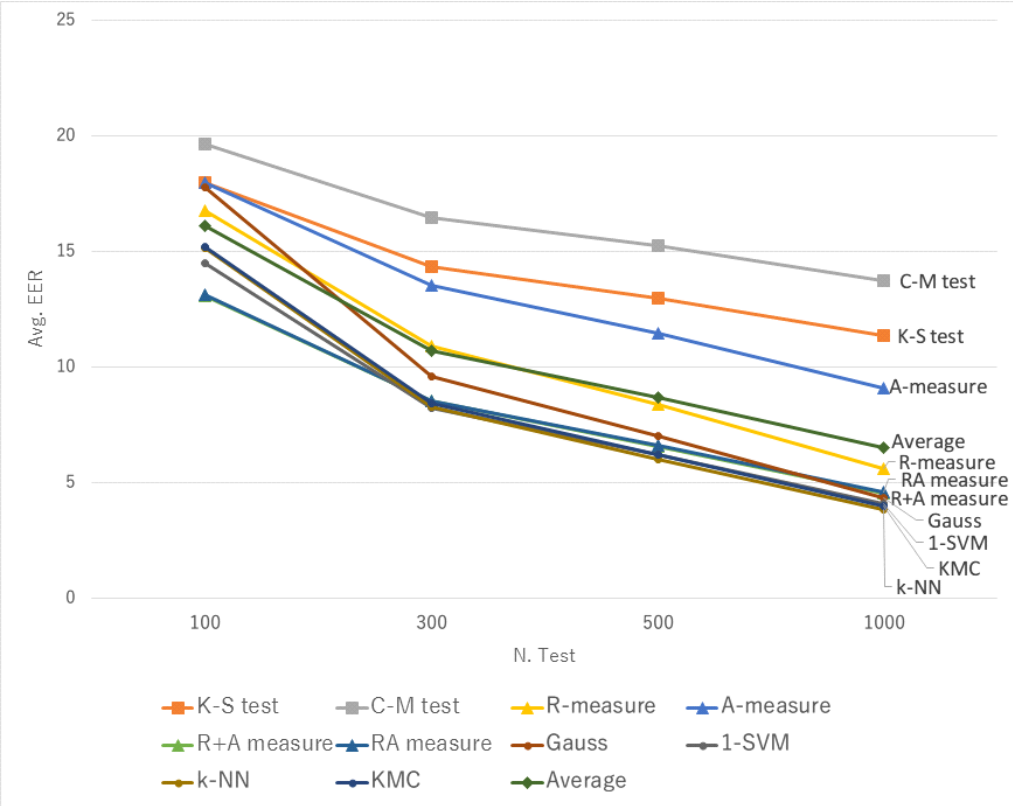

(d) Trn. data size: 1000

Fig. 5.2 EERs(%) over all training-test length combinations for each authentication algorithm (x-axis: test data length, y-axis: average EER)

3. 사용 데이터 언어에 따른 인증 성능

제 Ⅳ장에서 언급된 바와 같이 본 연구에서는 한국어를 모국어로 하는 100명의 한국인이 피실험자로 참여하였다. 비교적 친숙한 언어인 한국어와 그렇지 않은 영어를 사용하여 나타난 결과를 각 알고리즘별로 비교한 그래프는 Fig. 5.3에 나타나 있다. 모든 알고리즘에 대해 대체로 한국어가 영어와 비슷하거나 더 낮은 평균 EER을 보였고 한국어는 키 시퀀스를 사용한 기계학습 기반 방법인 가우시안 밀도 추정에서 가장 낮은 평균 EER 6.95%, 영어는 키 시퀀스를 사용한 기계학습 기반 방법인 k-NN에서 가장 낮은 평균 EER 8.23%로 나타났다.

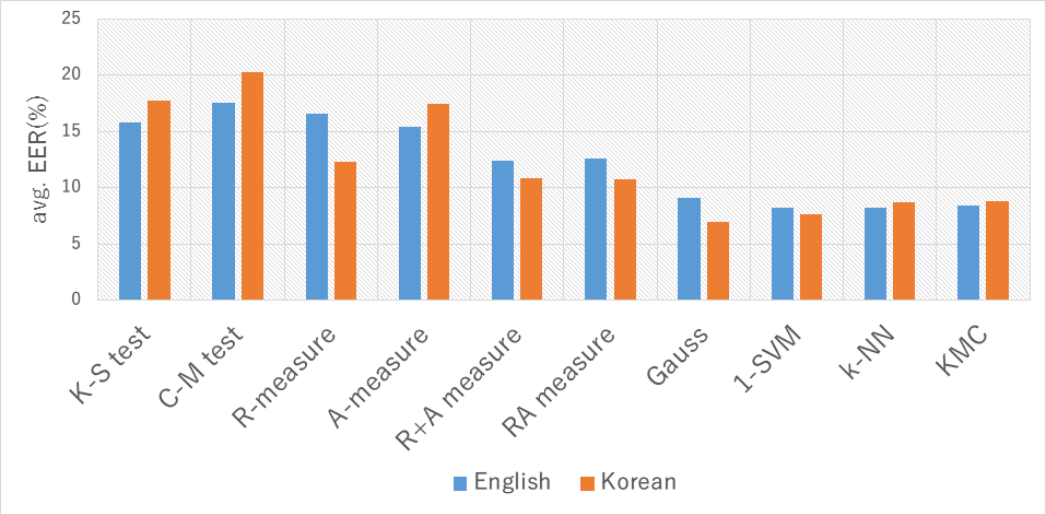

Fig. 5.3 EERs(%) for each language and authentication algorithm

4. 변수 조합 방법 및 사용 변수에 따른 인증 성능

본 연구에서는 Duration1, Duration2, Interval, Latency의 4개(키 시퀀스를 사용하지 않은 방법에서는 Duration1, Interval, Latency의 3개)의 변수 집합을 사용하였고 인증 성능을 높이기 위해 모든 변수 집합을 결합한 변수 조합 방식 또한 사용하였다. 각 데이터 사이즈에 대해 변수 별 인증 성능의 비교는 Table 5.2와 Fig. 5.4에 나타나 있다. 각 데이터 사이즈 별로 가장 낮은 EER은 굵은 글씨로 강조되어 있다. Table 5.2를 보면 데이터 크기에 상관없이 모든 경우에 대해 변수 조합 방식이 가장 좋은 인증 성능을 보이는 것으로 나타났다. 그 다음으로 Duration1, Duration2, Interval, Latency 순으로 인증 성능이 우수한 것으로 판별되었다. 특히, 변수 조합 방식은 Latency를 개별 사용할 때보다 EER 기준 최소 약 3배 이상 더 높은 인증 성능을 보였으며 인증 성능의 향상은 모든 알고리즘에 적용되는 것을 Fig. 5.4를 통해서도 확인할 수 있다.

앞서 언급된 것처럼 변수 조합 방법을 이용한 방법은 모든 데이터 크기와 모든 알고리즘의 경우에 개별 변수 집합을 사용한 방법보다 항상 우수한 인증 성능을 나타내었다.

Table 5.2 EERs(%) over all authentication algorithms and languages for each variable and training-test length combination

N. Traning	Variable	N. Test data			
		100	300	500	1000
100	Duration1	18.49	14.16	12.52	10.58
	Duration2	10.43	5.93	4.72	3.39
	Interval	26.65	20.73	18.66	16.24
	Latency	26.00	20.01	17.78	15.20
	Combine	13.41	8.57	7.09	5.57
300	Duration1	15.19	10.98	9.40	7.60
	Duration2	11.06	6.07	4.66	3.12
	Interval	24.38	17.61	15.04	12.24
	Latency	23.67	16.62	13.92	10.93
	Combine	10.74	6.06	4.71	3.41
500	Duration1	14.09	9.92	8.34	6.67
	Duration2	11.54	6.36	4.97	3.27
	Interval	23.71	16.75	14.06	11.21
	Latency	23.00	15.78	12.86	9.77
	Combine	10.06	5.40	4.05	2.86
1000	Duration1	12.73	8.79	7.35	5.70
	Duration2	12.48	6.99	5.49	3.66
	Interval	22.70	15.73	12.77	9.86
	Latency	22.16	14.80	11.81	8.55
	Combine	9.11	4.69	3.40	2.20

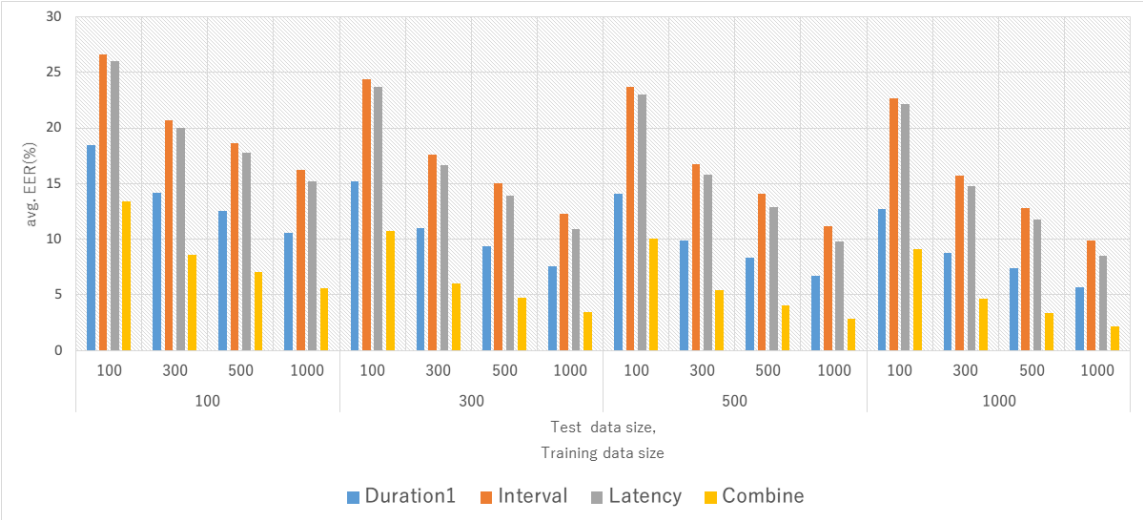

Fig. 5.4 Comparison among combined variable and other variables

가장 이상적인 상황에서 결과를 비교하기 위해 변수 조합 방법을 사용하고 테스트 데이터가 1000 키스트로크이고 키 시퀀스를 사용하는 기계학습 기반의 방법을 사용하는 가장 이상적인 상황에서 기계학습 알고리즘-언어-학습 데이터 크기 사이의 인증 성능을 비교하였으며, 그 결과는 Fig. 5.5에 나타난 바와 같다. 영어와 한국어 모두 가우시안 밀도 추정에서 학습 데이터의 크기가 300 키스트로크일 때 가장 낮은 인증 오류를 나타냈으며 영어와 한국어에서 EER 값은 각각 0.29% 및 0.59%로 확인되었다.

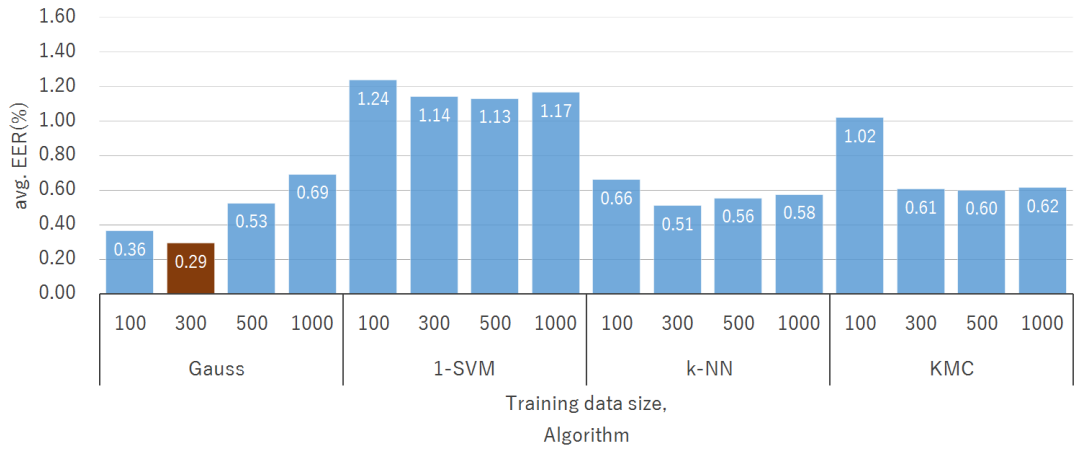

(a) English

(b) Korean

Fig. 5.5 Comparison among training data length and authentication algorithms

Ⅵ. 결 론

자유로운 문자열 입력에 대한 키스트로크 다이나믹스 기반 사용자 인증에서는 학습 데이터와 테스트 데이터를 비교할 때 각 데이터의 크기, 나타나는 문자열의 순서 및 조합이 서로 달라 비교가 어려운 문제가 있다. 따라서 특성을 추출하고 데이터를 샘플링하는 방법은 중요한 문제이다.

본 연구에서는 키 시퀀스를 사용하지 않는 방법에서 단일 키(monograph)와 두 개의 키 조합(digraph)의 각각의 시간 정보를 사용하여 K-S 검정과 C-M 검정을 통해 인증을 시도하였다. 그리고 키 시퀀스를 사용하는 통계적 기반 방법에서 두 개의 키 조합(digraph)과 어떤 키를 눌렀는지에 대한 키 시퀀스 정보(keycode)를 사용하여 ‘R’과 ‘A’ 지표 그리고 ‘R+A’와 ‘RA’ 지표를 통해 시간 정보의 상대적 차이와 절대적 비교를 수행하였다. 마지막으로 키 시퀀스를 사용하는 기계학습 기반 방법에서는 개별 키 입력을 키보드의 실제 입력 구간에 따라 세 가지 입력 구간으로 나누었다. 그 결과 두 개의 키 조합(digraph)에 대한 경우의 수를 8가지로 줄여 자유로운 문자열 입력의 비교가 가능하게 하였다.

인증 성능을 평가하기 위하여 100명의 피실험자로부터 한국어와 영어 각각 17,000 키스트로크 이상으로 이루어진 키스트로크 데이터를 수집하였다. 수집된 데이터로부터 Duration1, Duration2, Latency, Interval 네 가지의 시간 특성(키 시퀀스를 사용하지 않는 방법에서는 Duration1, Latency와 Interval의 세 가지)을 추출하여 인증에 사용하였으며 개별 변수의 결과를 조합한 변수 조합 방법도 제안하였다. 변수 조합은 인증 알고리즘과 언어, 데이터 크기에 상관없이 개별 변수 사용의 결과보다 항상 더 나은 인증 성능을 보였다. 사용된 인증 알고리즘 중에서는 가우시안 밀도 추정이 좋은 인증 성능을 보였고, 가우시안 밀도 추정에서는 학습 데이터의 크기가 300 키스트로크이고 테스트 데이터의 크기가 1000 키스트로크일 때 변수 조합 방법으로 영어 0.29%, 한글 0.59%의 낮은 EER을 달성하였다.

또한, 비교적 분당 타수의 편차가 작아 인증이 힘들 것으로 생각되었던 한국어의 인증 성능이 모든 알고리즘에서 영어와 비슷하거나 더 좋은 것으로 나타났다. 그리고 피실험자들에게 비교적 타이핑이 친숙하지 않은 영어도 모국어인 한국어에 준하는 결과를 보였기 때문에 언어에 상관없이 키스트로크 다이나믹스 기반 사용자 인증이 가능하다고 생각할 수 있다.

향후 연구방향은 본 연구에서 두 개의 언어 중 하나의 언어만 사용하는 경우

를 가정하여 실험을 실시하였는데 현실 세계에서는 두 개의 언어를 혼용해 사용하는 경우가 있으므로 한글과 영어가 혼용된 자유로운 텍스트 기반의 인증을 시도할 수 있을 것이다. 그리고 데이터의 크기가 클수록 더 나은 인증 성능을 보이는 경향이 있었기 때문에 초기 데이터로 인증 모델을 학습한 이후에 컴퓨터를 사용하며 자유롭게 입력되는 정보로 인증 모델을 다시 학습하여 인증 성능을 향상시키는 연구가 진행되어야 할 것이다.

참고문헌

[1] Niinuma, K. et al. (2010), Soft biometric traits for continuous user authentication, Information Forensics and Security, IEEE Transactions on, 5(4), 771-780.

[2] Kaganov, V. et al. (2014), Hybrid method for active authentication using keystroke dynamics, Hybrid Intelligent Systems (HIS), 2014 14th International Conference on. IEEE, 61-66.

[3] Hayashi, E. et al. (2013), Casa: context-aware scalable authentication, Proceedings of the Ninth Symposium on Usable Privacy and Security. ACM.

[4] Kassim, M. M. and Sujitha, A. (2013), ProcurePass: A User Authentication Protocol to Resist Password Stealing and Password Reuse Attack, Computational and Business Intelligence (ISCBI), 2013 International Symposium on. IEEE, 31-34.

[5] Jain, A. K. et al. (2006), Biometrics: a tool for information security, Information Forensics and Security, IEEE Transactions on, 1(2), 125-143.

[6] Jain, A. K. et al. (2004), An introduction to biometric recognition, Circuits and Systems for Video Technology, IEEE Transactions on, 14(1), 44-20.

[7] Samura, T. and Nishimura H. (2012), Influence of Keyboard Difference on Personal Identification by Keystroke Dynamics in Japanese Free Text Typing, Emerging Trends in Engineering and Technology (ICETET), 2012 Fifth International Conference on. IEEE, 30-35.

[8] Roth, J. et al. (2013), Biometric authentication via keystroke sound, Biometrics (ICB), 2013 International Conference on. IEEE, 1-8.

[9] Ahmed, A. A and Traore, I. (2014), Biometric recognition based on free-text keystroke dynamics, Cybernetics, IEEE Transactions on, 44(4), 458-472.

[10] Bours, P. and Mondal, S. (2015), Continuous Authentication with Keystroke Dynamics, Recent advances in user authentication using keystroke dynamics biometrics, 41-58, Science Gate Publishing, Xanthi, Greece.

[11] Alsultan, A. and Warwick, K. (2013), Keystroke dynamics authentication: a survey of free-text methods, International Journal of Computer Science Issues, 10(4), 1-10.

[12] Davoudi, H. and Kabir, E., (2009) A new distance measure for free text

keystroke authentication, Computer Conference 2009. CSICC 2009. 14th International CSI. IEEE, 570-575.
[13] Monrose, F. and Rubin, A. D. (2000), Keystroke dynamics as a biometric for authentication, Future Generation computer systems, 16(4), 351-359.
[14] Gunetti, D. and Picardi, C. (2005) Keystroke analysis of free text, ACM Transactions on Information and System Security (TISSEC), 8(3), 312-347.
[15] Ashbourn, J. (2000), The distinction between authentication and identification, Avanti Biometric Reference Site, http://ntlworld.com/avanti.
[16] Kang, P-S. and Cho, S-Z. (2015), Keystroke dynamics-based user authentication using long and free text strings from various input devices, Information Sciences, 308, 72-93.
[17] David, M. J. (2001), One-class classification: Concept-learning in the absence of counter-examples, ASCI dissertation series, 65, Delft University of Technology, CD Delft, Netherlands.
[18] Manevitz, L. M. and Yousef, M. (2002), One-class SVMs for document classification, the Journal of machine Learning research, 2, 139-154.
[19] Shimshon, T. et al. (2010), Continuous verification using keystroke dynamics, Computational Intelligence and Security (CIS), 2010 International Conference on. IEEE, 411-415.

Abstract

User Authentication Based on Keystroke Dynamics of Free Character Strings

Seo, Dong Min
(Supervisor Lee, Won Young)
Dept. of Data Science
The Graduate School
Seoul National University of Science and Technology

User authentication is an important issue on computer network systems. Most of the current computer network systems use the ID-password string match as the primary user authentication method. However, in password-based authentication, whoever knows the password of a user can pretend to be a valid user. In this paper, we present a keystroke dynamics-based user authentication to resolve limitations of the password-based authentication. Since most of the previous studies employed a fixed-length text as input data, we aim to enhance the authentication power by employing variable-length free character strings as input data. We verify our methodology through an experiment with a total of 100 participants. Each user provided more than 17,000 keystrokes for both Korean and English. One-class classification algorithms are employed to build an authentication model. The experimental results show that our proposed method significantly improved the authentication performance compared to the existing approaches.